

CS314. Функциональное программирование

Лекция 23. Внутреннее устройство компилятора GHC

В. Н. Брагилевский

Направление «Фундаментальная информатика и информационные технологии»
Институт математики, механики и компьютерных наук имени И. И. Воровича
Южный федеральный университет

24 декабря 2016 г.

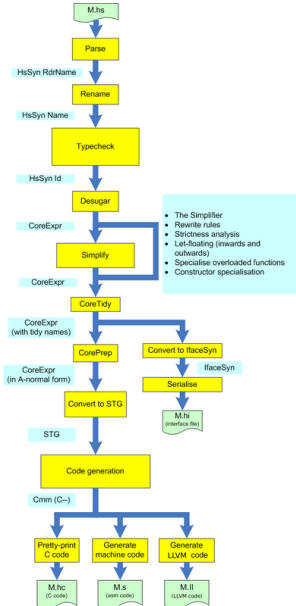
- Собственно компилятор
 - Менеджер компиляции
 - Компилятор одного модуля (Hsc)
 - Драйвер
- Базовые библиотеки (base)
- Runtime System (RTS)
- Система сборки

- 1 Компиляция одного модуля
- 2 Расширение возможностей компилятора

Содержание


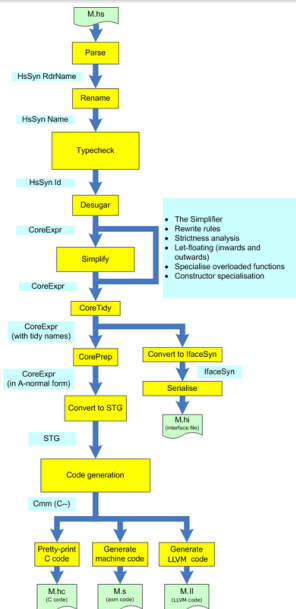
- 1 Компиляция одного модуля
- 2 Расширение возможностей компилятора

Общая схема



- 1 Разбор текста модуля (лексический и синтаксический анализ).
- 2 Разрешение имён.
- 3 Проверка типов.
- 4 Удаление синтаксического сахара и преобразование в Core.
- 5 Оптимизация.
- 6 Кодогенерация.

Компиляция модуля (1)



- `HsSyn` — дерево разбора (AST, Abstract Syntax Tree).
- `RdrName`, `Name` — имена с дополнительной информацией.

AST кода на Haskell (HsSyn) — модуль

```
data HsModule name
  = HsModule {
    hsmodName :: Maybe (Located ModuleName),
    hsmodExports :: Maybe (Located [LIE name]),
    hsmodImports :: [LImportDecl name],
    hsmodDecls :: [LHsDecl name],
    -- ...
  }
```

AST кода на Haskell (HsSyn) — определения


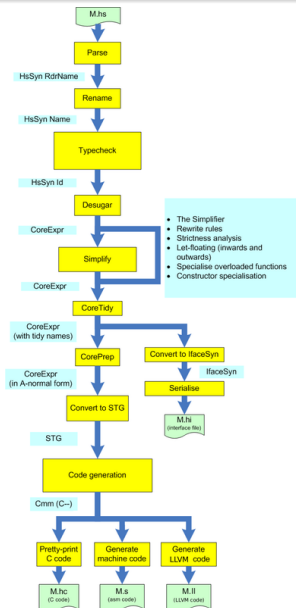
```
type LHsDecl id = Located (HsDecl id)
```

```
data HsDecl id
```

```



= TyClD      (TyClDecl id)      -- ^ Type or Class Declaration
| InstD      (InstDecl id)      -- ^ Instance declaration
| DerivD     (DerivDecl id)     -- ^ Deriving declaration
| ValD       (HsBind id)        -- ^ Value declaration
| SigD       (Sig id)           -- ^ Signature declaration
| DefD       (DefaultDecl id)   -- ^ 'default' declaration
| ForD       (ForeignDecl id)   -- ^ Foreign declaration
| WarningD   (WarnDecls id)     -- ^ Warning declaration
| AnnD       (AnnDecl id)       -- ^ Annotation declaration
| RuleD      (RuleDecls id)     -- ^ Rule declaration
| VectD      (VectDecl id)      -- ^ Vectorise declaration
| SpliceD    (SpliceDecl id)    -- ^ Splice declaration
                                   -- (Includes quasi-quotes)
| DocD       (DocDecl)          -- ^ Documentation comment
| RoleAnnotD (RoleAnnotDecl id) -- ^ Role annotation
```


Компильация модуля (2): проверка типов



- Id — имя с информацией о типе (каждое выражение по результатам проверки типов имеет тип, указанный явно или выведенный).

Компиляция модуля (3): Core и его оптимизация



- Удаление синтаксического сахара — преобразование во внутренний язык (Core).
- Оптимизация.

Внутренний язык Core

Синтаксис: выражения и паттерны

t, e, u	$::=$	x	Переменные
		K	Конструктор данных
		k	Литералы
		$\lambda x : \sigma. e \mid e \ u$	Абстракция и применение (значения)
		$\Lambda a : \eta. e \mid e \ \varphi$	Абстракция и применение (типы)
		$\text{let } \overline{x : \tau} = \overline{e} \text{ in } u$	Локальное связывание
		$\text{case } e \text{ of } \overline{p \rightarrow u}$	Выбор варианта
		$e \triangleright \gamma$	Преобразование типа значения (cast)
		$[\gamma]$	Приведение типа (coercion)
p	$::=$	$K \ \overline{c : \eta} \ \overline{x : \tau}$	Паттерны

- Греческие буквы — типы и сорта
- Надчёркивание — списки подтермов
- System FC

Алгебраический тип данных для Core

```
type CoreExpr = Expr Var
```

```
data Expr b
  = Var      Id
  | Lit      Literal
  | App      (Expr b) (Arg b)
  | Lam      b (Expr b)
  | Let      (Bind b) (Expr b)
  | Case     (Expr b) b Type [Alt b]
  | Cast     (Expr b) Coercion
  | Tick     (Tickish Id) (Expr b)
  | Type     Type
  | Coercion Coercion
  deriving (Data, Typeable)
```

```
type Arg b = Expr b
type Alt b = (AltCon, [b], Expr b)
data AltCon = DataAlt DataCon | LitAlt Literal | DEFAULT
data Bind b = NonRec b (Expr b) | Rec [(b, (Expr b))]
```

Оптимизация Core

- Упрощение (simplifier).
- Правила переписывания термов.
- Анализ строгости.
- Специализация перегруженных функций.
- Специализация конструкторов.
- ...

Пример кода Core

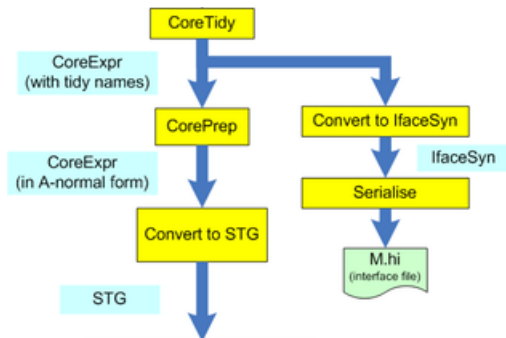

```
f a b = a + b
```

```
main = print $ f 2 3
```

```
$ ghc -c ex.hs -ddump-simpl
```

```
main :: IO ()  
[GblId, Str=DmdType]  
main =  
  print  
    @ Integer  
    GHC.Show.$fShowInteger  
    (+ @ Integer GHC.Num.$fNumInteger 2 3)
```

Компиляция модуля (4): подготовка к кодогенерации



- Построение нормальной формы.
- Генерация интерфейсного файла (для межмодульной оптимизации).
- STG — Spineless Tagless G-machine


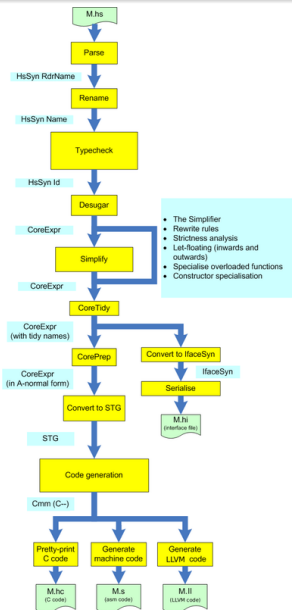
Фрагмент кода STG

```

sat_s10R :: GHC.Integer.Type.Integer
[LclId, Str=DmdType] =
  \u srt:SRT:[rp0 :-> GHC.Num.$fNumInteger] []
    let {
      sat_s10Q [Occ=Once] :: GHC.Integer.Type.Integer
      [LclId, Str=DmdType] =
        NO_CCS GHC.Integer.Type.S#! [3#]; } in
    let {
      sat_s10P [Occ=Once] :: GHC.Integer.Type.Integer
      [LclId, Str=DmdType] =
        NO_CCS GHC.Integer.Type.S#! [2#];
    } in  GHC.Num.+ GHC.Num.$fNumInteger sat_s10P sat_s10Q;
Main.main :: GHC.Types.IO ()
[GblId, Str=DmdType] =
  \u srt:SRT:[OB :-> System.IO.print,
    rLs :-> GHC.Show.$fShowInteger,
    s10R :-> sat_s10R] []
    System.IO.print GHC.Show.$fShowInteger sat_s10R;

```


Компиляция модуля (5): кодогенерация



- Cmm — низкоуровневый императивный язык с явным стеклом.

Фрагмент кода Cmm

```
I64[(old + 24)] = stg_bh_upd_frame_info;
I64[(old + 16)] = _c10Y::I64;
I64[Hp - 24] = GHC.Integer.Type.S#_con_info;
I64[Hp - 16] = 3;
_c111::P64 = Hp - 23;
I64[Hp - 8] = GHC.Integer.Type.S#_con_info;
I64[Hp] = 2;
_c112::P64 = Hp - 7;
R2 = GHC.Num.$fNumInteger_closure;
I64[(old + 48)] = stg_ap_pp_info;
P64[(old + 40)] = _c112::P64;
P64[(old + 32)] = _c111::P64;
call GHC.Num.+_info(R2) args: 48, res: 0, upd: 24;
```

Кодогенерация и RTS

Результаты кодогенерации

- Байт-код для интерпретации.
- Нативный код (на языке ассемблера).
- C-код.
- LLVM IR (промежуточный язык LLVM).

Функции RTS

- Управление памятью (в том числе сборка мусора).
- Управление потоками (потоки ОС и легковесные потоки приложения).
- Реализация примитивных операций.
- Подключение динамических библиотек и реализация FFI.
- Интерпретация байт-кода.

Содержание

- 1 Компиляция одного модуля
- 2 **Расширение возможностей компилятора**

Способы расширения функционала

- Определяемые пользователем правила переписывания термов.
- Плагины к компилятору.
- Компилятор как библиотека (GHC API).

Правила переписывания термов

```
{-# RULES "fold/build"
  forall k z (g::forall b. (a->b->b) -> b -> b) .
    foldr k z (build g) = g k z
#-}
```

- Применение семантически корректных преобразований.

Плагины к компилятору

- Плагин — это один проход на этапе оптимизации — функция из Core в Core в отдельном файле.
- Подключение флагом компилятора или директивой в исходном коде.
- Компилятор динамически подключает преобразование и выполняет его.
- Аннотации плагинов — способ указания места применения преобразования.

Компилятор как библиотека (GHC API)

- Модульность позволяет подменять отдельные этапы компиляции.
- Каждый этап — функция, которую может вызвать пользователь в собственной программе.
- Компилятор целиком или частично может встраиваться в программу пользователя.

- S. Marlow, S. Peyton Jones. The Glasgow Haskell Compiler. (Сборник The Architecture of Open Source Applications, vol. 2). <http://www.aosabook.org/en/ghc.html>

Репозитории с лабораторными работами

- Содержимое репозитория может быть удалено в любой момент, начиная с 01.02.2017.
- Прошу не публиковать и никаким образом не распространять задания и их решения.

Добор баллов

- Первый добор в день второй консультации (16 января), 14:00, а. 202:
 - Возможна сдача (досдача) проекта.
 - Переписывание контрольных работ 1 и 2.
- Последующие доборы:
 - Задания на добор формируются индивидуально в зависимости от набранных в семестре баллов (по темам с наименьшим количеством набранных баллов).
 - Задания на каждый следующий добор формируются с учётом результатов предыдущего.
 - Добор в феврале по материалам первого и второго модулей.
 - Начиная с марта на добор будут предлагаться задания по темам первого модуля.

- Экзамен проводится в письменной форме, продолжительность — 1,5 часа, начало в 08:30.
- В билете 25 вопросов, предполагающих короткие ответы (от одного слова до двух–трёх предложений).
- Ответ на каждый вопрос оценивается одним или двумя баллами.
- Экзамен считается сданным при наборе не менее чем 22 баллов.
- Всего за экзамен можно получить до 40 баллов.
- На странице курса опубликованы программа курса и демо-вариант экзамена.

Спасибо!